第三周+四周作业

【姓名+学校】：

【本周总投入时长】： 8小时

【完成项】： 完成部署Issac Sim环境，导入灵巧手URDF进行简单控制；学习强化学习算法

【关键问题与解决】： 暂无

【下周计划】： 下周学习

【需要帮助】： 暂无

部署环境截图

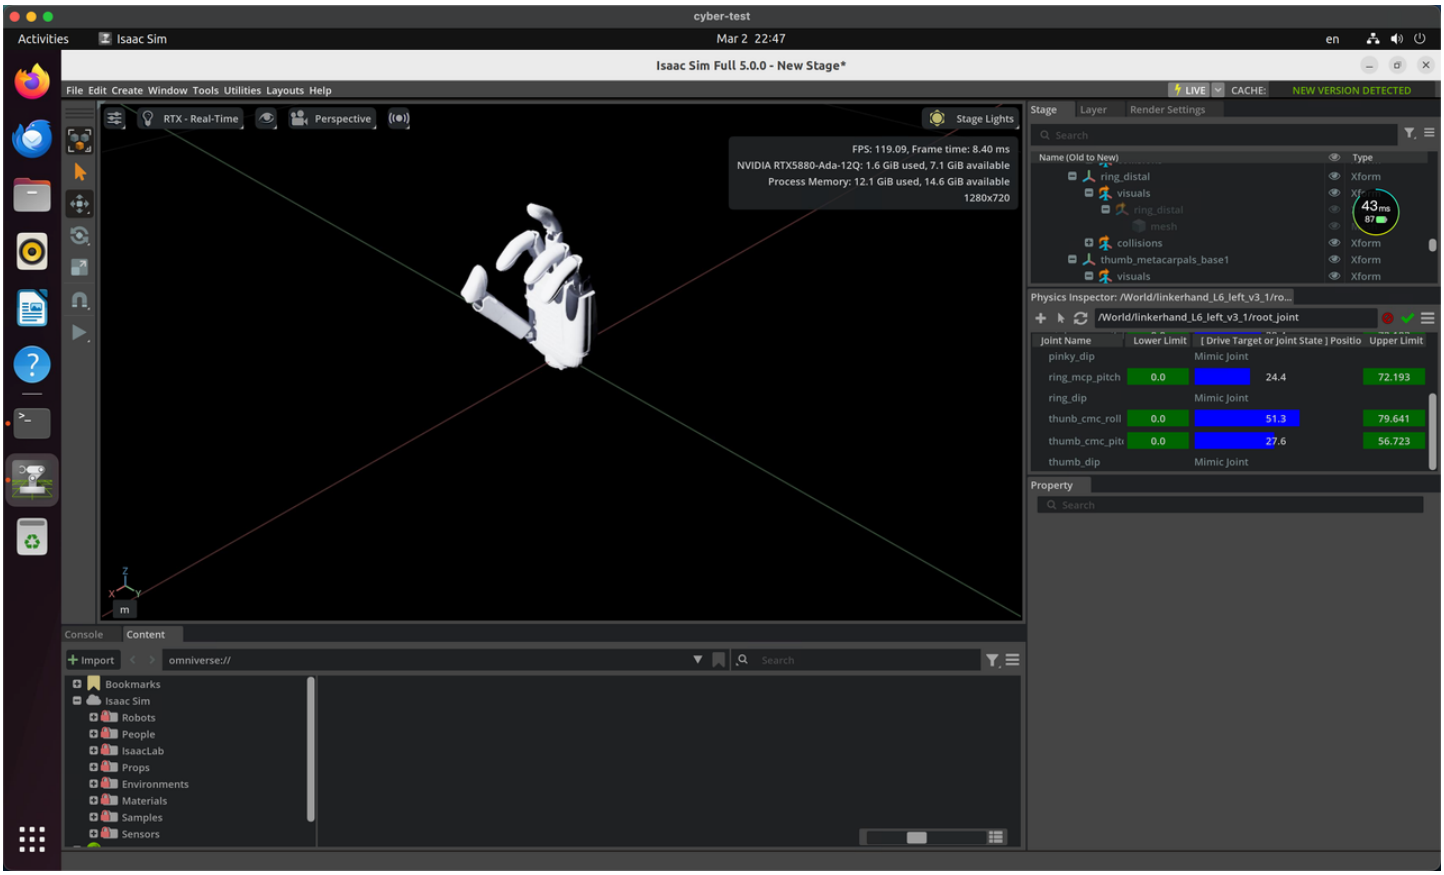

强化学习算法笔记

1. 简单说明 PPO 算法的核心思路

PPO (Proximal Policy Optimization, 近端策略优化) 要解决是传统的策略梯度（Policy Gradient）算法中，更新步长（Step Size）极其难以确定的问题。核心思路可以用一句话概括：**在“步子迈得大”和“学习得稳”之间找平衡，通过限制策略更新的幅度，确保新策略与旧策略之间的差异不会大到让训练失控。**

以下是它的三个核心支柱：

1.1 限制更新幅度 (Clipped Objective)

传统的策略梯度算法（如 Reinforce）如果一次更新步长太大，可能会导致策略突然崩溃。PPO 引入了一个“剪切”机制：

- **思路**：它会计算新旧策略的比例 $r_t(\theta)$。
- **做法**：如果新策略比旧策略好太多或差太多，PPO 会强行把这个比例限制在一个很小的区间内（通常是 [0.8, 1.2]）。
- **结果**：这保证了每次更新都是“微调”，不会因为某一次采样到的极端的随机结果而让模型产生剧烈波动。

1.2 重要性采样 (Importance Sampling)

PPO 属于 **On-policy** 算法，但它通过数学技巧实现了数据的复用：

- 它利用旧策略采集的数据来训练新策略。
- 通过重要性采样权重，它能修正新旧策略之间的分布差异，让每一批采集到的数据可以反复跑几个训练循环（Epochs），这大大提升了计算效率。

1.3 演员-评论家结构 (Actor-Critic)

PPO 通常采用 Actor-Critic 架构：

- **Actor (演员)**：负责做动作（比如控制机械臂旋转的角度）
- **Critic (评论家)**：负责给动作打分（预测当前状态的奖励总和值 ）
- 两者互相配合：Actor 根据 Critic 的反馈来决定以后多做哪些动作，少做哪些动作

2. 请判断 PPO 和 TD3 哪种算法更适合处理 “机器人关节连续转动” 这类动作（连续动作空间），并简单说说理由

在处理机器人关节连续转动这类连续动作空间任务时，**PPO（Proximal Policy Optimization）通常被认为是比 TD3（Twin Delayed DDPG）更适合初学者及大规模仿真场景的选择**，尽管两者在技术路径上各有千秋。

PPO 算法的核心优势在于其极高的训练稳定性和对复杂环境的适应能力。在机器人控制中，关节的连续转动往往涉及复杂的动力学反馈，如果学习步长控制不当，很容易导致机器人出现剧烈的震荡甚至物理崩溃。PPO 通过引入“剪切机制”，在数学层面上限制了新旧策略之间的差异，确保每一次参数更新都是在“安全区”内进行的微调。这种特性使得它在处理具有高维度状态空间的具身智能任务时，表现出极强的鲁棒性，不容易受到采样噪声的干扰。

相比之下，TD3 虽然是专门为连续动作空间优化的 Off-policy 算法，通过双评论家网络解决了价值高估的问题，并在数据利用效率上具有理论优势，但它的调参过程极其敏感。对于正在使用 Isaac Sim 进

行开发的工程师来说，PPO 的另一个关键胜出点在于它与大规模并行仿真的天然契合度。在无影云桌面提供的 GPU 算力下，PPO 可以轻松地在数千个并行环境中同时采集经验，这种“以量取胜”的策略往往能比精细调优的 TD3 更快地训练出能够稳健行走的机器人。

此外，PPO 属于随机性策略算法，它在动作输出中自带的“探索性”有助于机器人在复杂的物理接触（如足式机器人在不平整地面上行走）中找到更具弹性的控制方案。而 TD3 作为确定性策略算法，虽然在单一任务的精度补偿上可能更高，但在面对充满不确定性的真实物理仿真时，往往显得过于僵硬。因此，在目前的主流框架 如Isaac Lab 中，PPO 被选为大多数基准任务的默认算法。

3. 对比 PPO 和 MAPPO，说说 MAPPO 最核心的优势是什么？它主要是为解决什么类型的任务（单智能体 / 多智能体）而设计的？

MAPPO (Multi-Agent PPO) 是 PPO 算法在多智能体（Multi-Agent）领域的一种直接且高效的扩展。MAPPO 主要是为**多智能体任务（Multi-Agent Tasks）设计的，特别是合作型任务（Cooperative Tasks）**。 在这些任务中，多个机器人或智能体需要共同学习一套策略，以实现一个全局目标。

MAPPO 算法最核心的优势在于其采用了“中心化评价，去中心化决策”（Centralized Training, Decentralized Execution, CTDE）的框架，这使得它在保留 PPO 算法极佳训练稳定性的同时，有效解决了多智能体环境下的非平稳性问题。在多智能体任务中，每个智能体的策略更新都会改变其他智能体所面临的环境，这种相互影响会导致环境分布不断变化，使传统的单智能体算法难以收敛。MAPPO 通过引入一个能够观察全局状态、全局动作甚至其他智能体额外信息的中心化评论家（Critic）网络，为每个智能体提供了一个稳定且具有全局视野的评价基准。

在执行阶段，每个智能体仅需依靠自身的局部观测值，通过各自的演员（Actor）网络独立做出决策，这种设计既满足了训练时对全局协调的需求，又确保了实际部署时对局部自主性的要求。